



Diversa 

Análisis de datos con python



FLACSO
ECUADOR

Septiembre 2026

AGENDA

- ¿Qué es el análisis de datos?
- Breve evolución histórica: de la estadística clásica al big data y la IA
- Herramientas: ¿por qué Python? ¿por qué Colab?
- Caso práctico en Colab: primer contacto con un dataset
- Preguntas para la próxima clase





12 Clases · 20 Horas

CLASE 01

Intro a Ciencia de Datos y Colab

Conceptos de datos, Python, Google Colab, notebooks y celdas.

CLASE 02

Fundamentos de Python

Variables, tipos de datos, operaciones, `print()` y errores.

CLASE 03

Estructuras de Datos

Listas, diccionarios, condicionales y funciones aplicadas.

CLASE 04

Introducción a Pandas

DataFrames, CSV/Excel, `head()`, `tail()`, `shape` y `columns`.

CLASE 05

Exploración de Datos

Uso de `info()`, `describe()`, estadísticas descriptivas y selección.

CLASE 06

Filtrar y Ordenar

Filtros múltiples, ordenamiento y preguntas de investigación.

CLASE 07

Limpieza: Nulos y Duplicados

Tratamiento de valores ausentes, duplicados y datos incompletos.

CLASE 08

Limpieza: Formatos y Atípicos

Corrección de fechas, tipos, textos e identificación de atípicos.

CLASE 09

Agrupar y Comparar

Uso de `groupby()`, `agg()`, tablas de frecuencia y promedios.

CLASE 10

Visualización de Datos

Histogramas, barras, dispersión y boxplots con Matplotlib y Seaborn.

CLASE 11

Interpretación de Resultados

Patrones, correlación vs causalidad, conclusiones e IA responsable.

CLASE 12 · FINAL

Proyecto Final Integrador

Desarrollo y presentación de análisis completo con datos reales.



PROPÓSITO PRINCIPAL

Objetivo General

Comprender qué es el análisis de datos, identificar los grandes momentos de su evolución como campo, y familiarizarse con las herramientas (Python y Colab) que se usarán a lo largo del curso.

Objetivos Específicos

01 . DEFINICIÓN

Entender qué es el análisis de datos y cómo se diferencia de la estadística tradicional.

02 . EVOLUCIÓN HISTÓRICA

Identificar los grandes momentos del campo: estadística clásica, bases de datos, data mining, ciencia de datos, big data e IA.

03 . POR QUÉ PYTHON

Comprender por qué Python se volvió el lenguaje dominante: comunidad, librerías y curva de aprendizaje.

04 . POR QUÉ COLAB

Entender las ventajas de un entorno en la nube frente a instalación local: sin configuración, gratuito y colaborativo.

05 . PRIMER CONTACTO PRÁCTICO

Ejecutar las primeras celdas de código en Colab y cargar un dataset con pandas.

06 . PREGUNTA DE INVESTIGACIÓN

Empezar a definir un dataset propio y una pregunta preliminar para el proyecto del curso.

Análisis de datos

Lecturas recomendadas:

1. Kelleher, J. D. y Tierney, B. (2018). Data Science. MIT Press.: Capítulo introductorio: una explicación accesible de qué es la ciencia de datos y cómo se desarrolla un proyecto de análisis.
2. D'Ignazio, C. y Klein, L. F. (2020). Feminismo de datos.: Introducción: Por qué la ciencia de datos necesita del feminismo. Una invitación a pensar quién produce los datos, qué se cuenta y qué queda fuera. Disponible en español y en acceso abierto.
3. Wheelan, C. (2013). Naked Statistics: Stripping the Dread from the Data.





PREGUNTA PARA COMENZAR

¿Qué creen que cuenta como un dato?

PREGUNTA PARA EL GRUPO

¿Son datos por sí mismos?

¿Estos elementos son datos por sí mismos o se convierten en datos cuando alguien decide registrarlos, clasificarlos y utilizarlos?

01 . DATO PERSONAL

La edad de una persona

02 . MULTIMEDIA

Una fotografía

03 . COMUNICACIÓN

Un mensaje de WhatsApp

04 . PERCEPCIÓN

La percepción de inseguridad

05 . GEOLOCALIZACIÓN

Una ubicación

06 . OMISIÓN

El silencio o ausencia de respuesta

07 . REGISTRO RESIDUAL

Un registro de “otro” en una encuesta



¿Cuándo algo se convierte en dato?

CONCEPTO FUNDAMENTAL

Un dato no es simplemente “información que ya existe”.

Es una representación de la realidad que alguien decide observar, seleccionar, clasificar y registrar para algún propósito.

01 . OBSERVACIÓN

Se define qué observar

Edad, ubicación, una opinión, una palabra o una interacción.

02 . REPRESENTACIÓN

Se establece la forma

Un número, una categoría, un texto, una imagen o un audio.

03 . REGISTRO

Se almacena en soporte

Una encuesta, base de datos, una grabación o un sensor.

04 . ORGANIZACIÓN

Se estructura el análisis

Mediante variables, etiquetas, formatos o criterios comunes.



Concepto clave

¿Qué es el análisis de datos?

DEFINICIÓN PRINCIPAL

Es el proceso de inspeccionar, limpiar y transformar datos con el objetivo de extraer información útil y apoyar la toma de decisiones.

Transforma los datos brutos en conocimiento estratégico para guiar la acción y resolver problemas complejos.

DIFERENCIA 01

No es estadística pura

La estadística pura se ocupa principalmente de la teoría matemática abstracta y los fundamentos formales detrás de los datos.

DIFERENCIA 02

No es machine learning

El machine learning busca que un sistema aprenda patrones de forma automática para realizar predicciones avanzadas.



Información, datos y evidencia

Concepto	Ejemplo
Realidad o fenómeno	Personas enfrentan dificultades para acceder a vivienda
Información registrada	Respuestas obtenidas mediante una encuesta
Datos estructurados	Una tabla con ciudad, edad, ingresos y tipo de vivienda
Resultado del análisis	El 42 % reporta dificultades para pagar el alquiler
Evidencia interpretada	El problema se concentra en determinados grupos o territorios



Concepto Clave

¿Qué es analizar datos?

Analizar datos es utilizar información organizada para responder una pregunta.

El proceso generalmente incluye:



CONSIDERACIÓN CRÍTICA

Pero el proceso no siempre es lineal.

Al explorar los datos podemos descubrir errores, limitaciones o incluso que necesitamos reformular la pregunta.



Historia y Hitos de la Ciencia de Datos

01 . SIGLO XIX-XX

Estadística Descriptiva

Hacking (1990): La estadística como forma de conocimiento. Hollerith desarrolló tarjetas perforadas (década de 1880) para el procesamiento mecánico masivo de datos.

02 . AÑOS 70

Bases de Datos Relacionales

Codd, E. F. (1970): Publica "*A Relational Model of Data for Large Shared Data Banks*", sentando las bases de la estructuración moderna de datos.

03 . AÑOS 60-70

Origen del Término

Tukey (1962) propone el análisis de datos como ciencia empírica. Naur (1974) introduce "ciencia de datos" como alternativa a la informática.

04 . AÑOS 80-90

Data Mining & KDD

Fayyad, Piatetsky-Shapiro & Smyth (1996): Definen el proceso de Descubrimiento de Conocimiento en Bases de Datos (KDD).

05 . 2001-2008

Consolidación del Campo

Cleveland (2001) establece un plan de acción formal. Hacia 2008 se populariza el rol corporativo de "Data Scientist" (Patil y Hammerbacher).

06 . 2010+

Big Data & Deep Learning

Mayer-Schönberger & Cukier (2013) impulsan la era del Big Data. LeCun, Bengio & Hinton (2015) consolidan el Deep Learning en IA.

Del problema al *código*

Lecturas recomendadas:

1. Google Colab. Introducción a Colaboratory: entorno, notebooks, celdas de código y texto.
2. Severance, C. (2016). Python para todos, capítulos 1 y 2: variables, expresiones e instrucciones.
3. VanderPlas, J. (2016). Python Data Science Handbook, capítulo 1: primeros pasos con IPython y notebooks.





¿Por qué Python?

01 . SINTAXIS

Legible y Accesible

Lenguaje de propósito general con sintaxis clara y curva de aprendizaje suave.

02 . ECOSISTEMA

Librerías para Datos

Ecosistema robusto: pandas (tablas), numpy (cálculo) y matplotlib/seaborn (visualización).

03 . COMUNIDAD

Código Abierto

Gratuito, de código abierto, respaldado por una comunidad global activa y abundante documentación.

04 . BALANCE

Frente a Excel y R

Supera el límite de Excel y ofrece mayor versatilidad práctica que R, equilibrando accesibilidad y potencia.



El Estándar en Ciencia de Datos


El equilibrio perfecto entre potencia computacional y facilidad de integración.

¿De qué formas se puede usar Python?

01 . EN TU EQUIPO

Instalación Local

Se instala Python en la computadora (Anaconda o python.org) y se edita en VS Code o PyCharm. Requiere configuración inicial.



02 . INTERACTIVO

Jupyter Notebook

Entorno interactivo por celdas ejecutado localmente. Permite mezclar código, texto y resultados, pero depende de instalación previa.



03 . EN LA NUBE

Notebooks en la Nube

Misma lógica de celdas ejecutada en servidores remotos (Google Colab, Kaggle). Sin necesidad de instalar nada en tu equipo.



★ **SELECCIÓN DEL CURSO:** Usaremos la tercera opción, Google Colab por su accesibilidad inmediata y cero necesidad de configuración previa.



Google Colab: Guía y Ventajas



01 . VENTAJAS

Por qué usarlo

- Sin instalación: Se abre directamente en el navegador.
- Acceso fácil: Compatible con cualquier cuenta de Google (Gmail).
- Google Drive: Integración y guardado automático.
- Colaborativo: Edición en tiempo real estilo Google Docs.
- Preinstalado: Incluye Python, pandas, numpy y matplotlib.



02 . LIMITACIONES

Aspectos a considerar

- Conectividad: Depende 100% de conexión a internet.
- Recursos limitados: Las sesiones gratuitas tienen restricciones de tiempo, RAM y GPU.
- Inactividad: Al cerrarse la sesión por inactividad, se requiere reejecutar las celdas desde el inicio.



03 . USO BÁSICO

Pasos iniciales

1. Entrar con cuenta de Google.
2. Crear notebook: Archivo → Nuevo notebook.
3. Organizado en celdas de código (Python) y texto (Markdown).
4. Ejecutar celdas con botón "Play" o **Shift + Enter**.
5. Guardado automático en la carpeta "Colab Notebooks" en Drive.

ENLACE DIRECTO DE ACCESO: <https://colab.research.google.com>



Dos tipos de celdas

En Google Colab trabajaremos principalmente con dos tipos de celdas.



01 . TEXTO & DOCUMENTACIÓN

Celdas de texto o Markdown

Sirven para:

- Escribir títulos.
- Explicar el análisis.
- Documentar decisiones.
- Interpretar resultados.
- Escribir conclusiones.



02 . EJECUCIÓN & LÓGICA

Celdas de código

Sirven para:

- Dar instrucciones a Python.
- Realizar cálculos.
- Importar datos.
- Limpiar información.
- Crear tablas y gráficos.

★ **IDEA CLAVE:** *El código muestra qué hicimos; el texto explica por qué lo hicimos y qué significa.*



Conceptos Técnicos Básicos

Inteligencia Artificial (IA)

Campo de la informática que desarrolla sistemas capaces de realizar tareas que normalmente requieren "inteligencia" humana: reconocer patrones, tomar decisiones, generar texto o imágenes.

Algoritmo

Conjunto de instrucciones o reglas que un sistema sigue para resolver un problema o realizar una tarea.

Modelo

El resultado de entrenar un algoritmo con datos: una representación matemática que "aprendió" patrones y puede hacer predicciones o generar contenido nuevo.

Machine Learning (aprendizaje automático)

Subcampo de la IA donde los sistemas aprenden patrones a partir de datos, en lugar de seguir reglas programadas explícitamente.

Deep Learning (aprendizaje profundo)

Tipo de machine learning que usa redes neuronales con muchas capas para procesar datos complejos (imágenes, voz, texto).

Red neuronal

Estructura computacional inspirada (de forma simplificada) en el cerebro humano, compuesta por nodos interconectados que procesan información en capas.

Datos de entrenamiento

El conjunto de datos que se usa para "enseñarle" patrones a un modelo. Su calidad, origen y representatividad determinan en gran medida el comportamiento del sistema.

Modelos de Lenguaje Grandes (LLM)

Modelos entrenados con grandes volúmenes de texto para predecir y generar lenguaje (ej. ChatGPT, Claude).

IA generativa

Sistemas capaces de crear contenido nuevo como texto, imágenes, audio, código a partir de patrones aprendidos de datos existentes.

Sesgo algorítmico

Distorsiones sistemáticas en los resultados de un sistema de IA, que suelen reproducir o amplificar desigualdades presentes en los datos o en el diseño.



Valoramos la generación de estos
espacios de discusión sobre esta tecnología

Gracias por *repensar* el uso de los
datos y la inteligencia artificial

diana@diversa.studio hello@diversa.studio <https://diversa.studio>



[@diversa_ai](#)



[diversa-ai](#)

CC BY-NC-ND 4.0

Creative Commons Atribución-NoComercial-SinDerivadas 4.0 Internacional.

Esta licencia exige que quienes reutilicen el material den crédito a la persona creadora. Permite copiar y distribuir el material en cualquier medio o formato, únicamente en su forma original y para usos no comerciales.

BY — Atribución Se debe dar crédito a la persona creadora.

NC — NoComercial Solo se permite el uso no comercial de la obra. No comercial significa que no está principalmente destinado ni orientado a obtener ventajas comerciales o compensación económica.

ND — SinDerivadas No se permiten obras derivadas ni adaptaciones del material original.





Las 7 secciones de una datasheet

01. MOTIVACIÓN

¿Por qué y para quién? El origen y propósito detrás de la creación del conjunto de datos.

02. COMPOSICIÓN

Estructura interna: Qué representa cada instancia, si incluye subpoblaciones o datos sensibles.

03. PROCESO DE RECOLECCIÓN

Adquisición de datos: Mecanismos de obtención, consentimiento de las partes y procesos de notificación.

04. PREPROCESAMIENTO Y LIMPIEZA

Preparación: Qué acciones se realizaron sobre los datos crudos antes de que fuesen utilizados.

05. USOS RECOMENDADOS

Casos de uso: Para qué tareas específicas resulta de utilidad y en cuáles escenarios no debería emplearse.

06. DISTRIBUCIÓN

Aspectos legales: Licenciamiento del dataset, restricciones de propiedad intelectual y términos de uso.

07. MANTENIMIENTO

Sostenibilidad: Entidad que lo respalda, políticas de actualización y límites de retención de la información.